Metody numeryczne dla astronomów
Ćwiczenia 3

Aproksymacja

Aproksymacja, czyli przybliżanie, jest bardzo często używaną techniką w astronomii. Najczęściej przybliża się coś skomplikowanego (np. brzydką funkcję nieróżniczkowalną) czymś prostszym (np. kombinacją liniową funkcji różniczkowalnych). Bardzo dobrym przykładem jest sygnał prostokątny, który np. można wytworzyć za pomocą generatorów dźwięku. Standardowy generator może wytwarzać tylko fale sinusoidalne, można jednak modyfikować ich amplitudę i częstość. Jak wytworzymy odpowiednio wiele takich fal o dobranych parametrach, to będziemy w stanie stworzyć coś podobnego do fali prostokątnej, co wyraźnie widać na Rysunku 1.

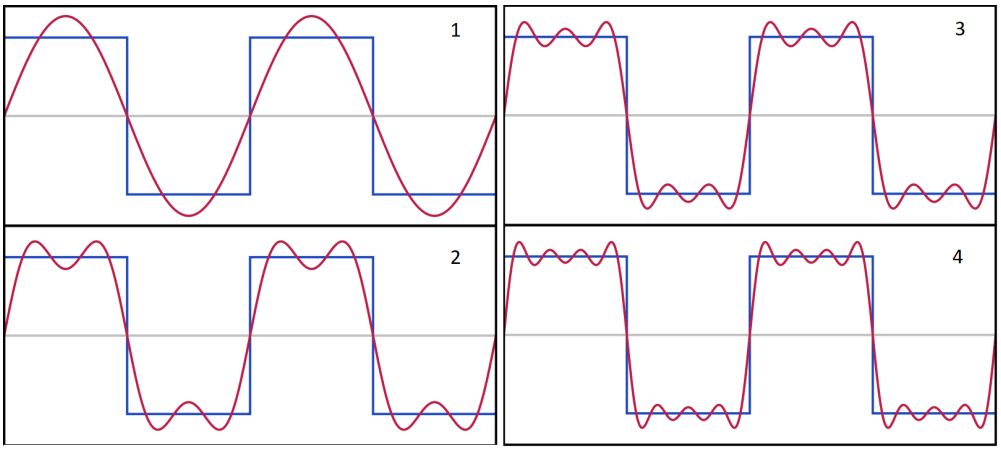

Rysunek 1: Aproksymacja funkcji prostokątej za pomocą kolejnych wyrazów szeregu Fouriera. Źródło: *https://en.wikipedia.org/wiki/Fourier_series*

W ogólności pewną funkcję $f(x)$ będziemy aproksymować klasą funkcji $\{g_n(x)\}_{n=0,1,2\ldots}$, którą mogą stanowić np. wielomiany, sinusy i cosinusy itd. Niech $g(x)$ będzie złożeniem takich funkcji $g_n(x)$, wówczas mamy:

$$g(x) = f_{\mathrm{apr}}(x) = f(x) + E(x) \quad \Rightarrow \quad E(x) = f(x) - g(x).$$

Funkcja $E(x)$ jest to tzw. *funkcja błędu*. Oczywiście chcemy, aby była ona jak najmniejsza, ponieważ wtedy nasza funkcja aproksymująca $g(x)$ będzie najbliżej wyjściowej funkcji $f(x)$.

Najpopularniejsze metody aproksymacji:
1) Aproksymacja liniowa – naszą funkcją aproksymującą będzie funkcja liniowa.
Rozpiszmy wzór na pochodną:

$$f'(a) = \lim_{x \to a} \frac{f(x) - f(a)}{x - a} = \frac{f(x) - f(a)}{x - a} + r. \tag{1}$$

Przekształcając dalej:

$$f'(a)(x - a) = f(x) - f(a) + r(x - a) = f(x) - f(a) + R, \tag{2}$$

gdzie wprowadziliśmy $R = r(x - a)$. Wtedy:

$$f(x) = f(a) + f'(a)(x - a) + R. \tag{3}$$

Zauważmy, że ponieważ a, $f(a)$ i $f'(a)$ to są pewne stałe (niezależne od x), to otrzymaliśmy aproksymację $f(x)$ za pomocą funkcji liniowej w x, gdzie $R = E$ jest funkcją błędu. Nasza funkcja aproksymująca będzie miała postać:

$$g(x) = f(a) + f'(a)(x - a). \tag{4}$$

Im bliżej x jest a, tym lepsze przybliżenie. Powyższy wzór jest oczywiście niczym innym, jak wzorem na styczną do wykresu funkcji $f(x)$ w punkcie $(a, f(a))$.

Zadanie 1
Korzystając z aproksymacji liniowej, policz przybliżoną wartość:
a) $\sqrt{2}$
b) $\sqrt[3]{25}$ – to jest zadanie dla Was

Rozwiązanie
a) Niech $f(x) = x^{\frac{1}{2}}$. Wtedy $f'(x) = \frac{1}{2}x^{-\frac{1}{2}}$. Chcemy wyznaczyć wartość $f(2)$, ale nie znamy wartości $\sqrt{2}$. Wiemy za to, że $f(4) = \sqrt{4} = 2$. Teraz dokonujemy aproksymacji liniowej:

$$f(2) \approx f(4) + f'(4)(2 - 4) = 2 + \frac{1}{2} \cdot \frac{1}{2}(-2) = 1.5$$

Prawdziwa wartość $\sqrt{2} \approx 1.41$, czyli nie jest najgorzej, jak na tak prostą metodę.

2) Aproksymacja jednostajna – tworzymy funkcję błędu:

$$E = \max_{x \in [a,b]} |g(x) - f(x)|.$$

Jest to maksymalne odchylenie naszej funkcji aproksymującej $g(x)$ od funkcji wyjściowej $f(x)$. Chcemy, aby ta wartość była minimalna. Metoda ta jest rzadko stosowana z uwagi na

dużą czułość na odstające punkty.

3) Aproksymacja średniokwadratowa – funkcja błędu jest postaci:

$$E = \int_a^b w(x) \left[g(x) - f(x)\right]^2 \mathrm{d}x, \tag{5}$$

gdzie $w(x)$ to funkcje wagowe, które określają, jak ważny jest błąd w poszczególnych punktach.
Zdecydowanie częściej korzysta się z postaci dyskretnej, ponieważ zazwyczaj pracujemy na danych pomiarowych, do których coś dopasowujemy:

$$E = \sum_{i=1}^{n} w_i(x) \left[g(x_i) - f(x_i)\right]^2 . \tag{6}$$

Regresja liniowa

W ogólności jest to metoda estymowania (przybliżania) wartości oczekiwanej zmiennej y przy znanych wartościach innej zmiennej lub zmiennych x_i.
Regresja liniowa dotyczy więc sytuacji, w których $f = f(x_1, x_2, \ldots, x_n, a_1, a_2, \ldots, a_m)$. Człon *liniowa* oznacza, że funkcja ta jest liniowa względem parametrów dopasowania $\{a_i\}$, a niekoniecznie względem zmiennych x_i. W praktyce zwykle funkcjami składowymi są jednomiany $a_k x^l$.

Metoda Najmniejszych Kwadratów – MNK

Jedną z najpopularniejszych metod stosowanych przy regresji liniowej jest właśnie MNK.
Na czym polega ta metoda?
Mamy serię punktów pomiarowych $\{(x_i, y_i)\}$, razem z niepewnościami punktów $y_i - \sigma_i$.
Nasz problem sprowadza się do oszacowania wartości w punktach, które nie mieszczą się w podanej serii, a więc w punktach $(x_{j\neq i}, y_{j\neq i})$. Wartości te szacujemy na podstawie dostępnej próbki danych. Nasza funkcja błędu przyjmuje postać taką, jaką mieliśmy dla dyskretnej aproksymacji średniokwadratowej:

$$E = \sum_{i=1}^{n} w_i(x) \left[y_i - g(x_i)\right]^2 .$$

Powyższa funkcja definiuje nam **statystykę** χ^2. Dla regresji liniowej, w której składowymi są jednomiany otrzymujemy:

$$\chi^2 = \sum_{i=1}^{n} \frac{\left(y_i - \sum_{k=0}^{N} a_k x_i^k\right)^2}{\sigma_i^2}. \tag{7}$$

Dla serii danych postaci $\{(x_i, y_i, \sigma_{y_i})\}$, najczęściej przyjmowana waga to $w_i = 1/\sigma_{y_i}^2$, co oznacza, że im większą niepewność ma dany punkt, tym mniej nam na tym punkcie zależy.

Dopasowanie prostej do rozkładu punktów

Zajmijmy się teraz bardzo istotnym zagadnieniem dopasowywania prostej do rozkładu punktów $\{(x_i, y_i)\}$. Mamy więc funkcję $g(x) = ax + b$ i szukamy a oraz b. Podstawiamy postać funkcji $g(x)$ do naszej statystki χ^2:

$$\chi^2 = \sum_{i=1}^{n} \frac{(y_i - (ax_i + b))^2}{\sigma_i^2}. \tag{8}$$

Zauważmy, że funkcja χ^2 ("chi kwadrat", tak o niej mówimy – nie samo "chi") jest funkcją dwóch zmiennych: $\chi^2 = \chi^2(a, b)$. W aproksymacji naszym najważniejszym zadaniem zawsze jest minimalizowanie funkcji błędu. Skoro nasza funkcja błędu jest funkcją dwóch zmiennych, to chcemy:

$$\frac{\partial \chi^2}{\partial a} = 0, \ \frac{\partial \chi^2}{\partial b} = 0. \tag{9}$$

Do rozwiązania tych równań wygodne będzie wprowadzenie nowych zmiennych:

$$\begin{aligned} S &= \sum_{i=1}^{n} \frac{1}{\sigma_i^2}; \\ S_x &= \sum_{i=1}^{n} \frac{x_i}{\sigma_i^2}; \\ S_y &= \sum_{i=1}^{n} \frac{y_i}{\sigma_i^2}; \\ S_{xx} &= \sum_{i=1}^{n} \frac{x_i^2}{\sigma_i^2}; \\ S_{xy} &= \sum_{i=1}^{n} \frac{x_i y_i}{\sigma_i^2}. \end{aligned} \tag{10}$$

Zadnie 2 [2 punkty]
Wyznacz współczynniki a i b prostej $f(x) = ax+b$, dopasowanej do zbioru n punktów, korzystając z metody najmniejszych kwadratów. Zapisz je za pomocą zmiennych $S, S_x, S_y, S_{xx}, S_{xy}$ oraz nowej zmiennej $\Delta = S \cdot S_{xx} - (S_x)^2$.

Uwaga! *W tym zadaniu jest sporo liczenia, więc proszę nie zostawiać tego na ostatnią chwilę.*

Powinno wyjść:

$$\begin{aligned} a &= \frac{SS_{xy} - S_x S_y}{\Delta}; \\ b &= \frac{S_{xx} S_y - S_x S_{xy}}{\Delta}. \end{aligned} \tag{11}$$

Niepewności a i b wyliczymy z reguły propagacji błędu:

$$\begin{aligned} \sigma_a^2 &= \sum_{i=1}^{n} \sigma_i^2 \left(\frac{\partial a}{\partial y_i}\right)^2; \\ \sigma_b^2 &= \sum_{i=1}^{n} \sigma_i^2 \left(\frac{\partial b}{\partial y_i}\right)^2. \end{aligned} \tag{12}$$

A stąd:

$$\begin{aligned} \sigma_a^2 &= \frac{S}{\Delta}; \\ \sigma_b^2 &= \frac{S_{xx}}{\Delta}. \end{aligned} \tag{13}$$

Dobroć dopasowania

Jest to parametr, który mówi nam o tym, jak dobrze model statystyczny pasuje do danych.

Przykłady:
1) Współczynnik determinacji R^2:

$$R^2 = \frac{\sum_{i=1} \left(ax_i + b - \bar{y}\right)^2}{\sum_{i=1} \left(y_i - \bar{y}\right)^2}, \tag{14}$$

gdzie $\bar{y} = \sum_{i=1}^{N} y_i/N$. $R^2 \subset [0, 1]$. Im bliżej jedynki, tym lepiej.

2) Zredukowane χ^2
Wielkość ta określona jest poniższym równaniem:

$$\chi_\nu^2 = \frac{\chi^2}{dof} = \frac{\chi^2}{n - c}. \tag{15}$$

Parametr dof to liczba stopni swobody (*degrees of freedom*), a c to liczba parametrów modelu. Co nam mówią wartości χ_ν^2:

- $\chi_\nu^2 >> 1$ – jest bardzo źle
- $\chi_\nu^2 > 1$ – dopasowanie nie pokrywa w całości danych lub niepewności σ_i są niedoszacowane
- $\chi_\nu^2 \approx 1$ – idealne dopasowanie
- $\chi_\nu^2 < 1$ – overfitting lub przeszacowanie σ_i

Inne użyteczne parametry

1) Błąd średniokwadratowy
Inaczej nazywany RMSD lub RMSE, chociaż bardzo często błędnie używa się nazwy RMS:

$$\text{RMSD} = \sqrt{\frac{\sum_{i=1}^{N} \left(y_i - ax_i - b\right)^2}{n}}. \tag{16}$$

W praktyce RMSD daje nam informację o średnim rozrzucie danych wokół dopasowania.

2) Współczynnik korelacji liniowej Pearsona r

Używamy go, gdy chcemy sprawdzić, jak bardzo liniowy jest rozkład (uwaga: nie ma on nic wspólnego z dopasowywaną funkcją i nie bierze jej pod uwagę). Wyznacza się go ze wzoru:

$$r = \frac{SS_{xy} - S_x S_y}{\sqrt{(SS_{xx} - S_x^2)(SS_{yy} - S_y^2)}} \tag{17}$$

Jeżeli wszystkie niepewności zmiennej y są równoważne i równe jedynce, wtedy zmienna $S = \sum_1^n 1 = n$, a współczynnik r zdefiniowany jest w sposób:

$$r = \frac{n \sum_{i=1}^n x_i y_i - \sum_{i=1}^n x_i \sum_{i=1}^n y_i}{\sqrt{n \sum_{i=1}^n x_i^2 - \left(\sum_{i=1}^n x_i\right)^2} \sqrt{n \sum_{i=1}^n y_i^2 - \left(\sum_{i=1}^n y_i\right)^2}}. \tag{18}$$

Gdy $r = 1$ korelacja jest idealna, $r = 0$ oznacza brak korelacji, a $r = -1$ to korelacja negatywna.